

# 卒 業 論 文

## 測域センサの反射強度を利用した視覚と行動の end-to-end 学習による人追従行動の模倣

Imitation-based end-to-end learning for human tracking behavior  
using reflected intensity from range sensors

2023 年 12 月 28 日 提出

指導教員 林原 靖男 教授

千葉工業大学 先進工学部 未来ロボティクス学科

20C1102 馬場 琉生



# 概要

## 測域センサの反射強度を利用した視覚と行動の end-to-end 学習による人追従行動の模倣

本研究室でも、機械学習を用いた画像に基づく人追従行動の生成に関する研究を行ってきた  
[1][2][3][4].

キーワード: 人追従, end-to-end 学習, モバイルロボット

# abstract

Imitation-based end-to-end learning for human tracking behavior  
using reflected intensity from range sensors

keywords: Person following, End-to-end learning, Mobile robot

# 目次

第 1 章	序論	1
1.1	背景 . . . . .	1
1.2	目的 . . . . .	4
1.3	関連研究 . . . . .	5
1.4	論文の構成 . . . . .	7
第 2 章	要素技術	8
2.1	深層学習 . . . . .	8
2.2	end-to-end 学習 . . . . .	9
2.3	Convolutional Neural Network (CNN) . . . . .	10
2.4	ROS . . . . .	12
2.4.1	LiDAR . . . . .	12
2.4.2	RViz . . . . .	13
第 3 章	従来手法	14
3.1	学習フェーズ . . . . .	14
3.2	追従フェーズ . . . . .	15
3.3	ネットワークの構造 . . . . .	16
第 4 章	提案手法	17
4.1	提案手法の概要 . . . . .	17
4.2	学習フェーズ . . . . .	18
4.3	追従フェーズ . . . . .	19

目次	vi
4.4	ルールベース制御器 . . . . . 20
4.5	ネットワーク構造 . . . . . 21
第 5 章	実験 22
5.1	実験の手順 . . . . . 22
5.2	実験装置 . . . . . 23
5.3	実験 1 LiDAR の反射強度の実験 . . . . . 24
5.3.1	実験目的 . . . . . 24
5.3.2	壁の反射強度 . . . . . 25
5.3.3	再帰反射テープの反射強度 . . . . . 26
5.3.4	学習する場所付近の反射強度 . . . . . 27
5.3.5	反射強度を利用した人追従の実験 . . . . . 28
5.4	実験 2 提案手法による人追従の実験 . . . . . 29
5.4.1	実験目的 . . . . . 29
5.4.2	実験方法 . . . . . 29
5.4.3	結果と考察 . . . . . 29
第 6 章	結論 32
参考文献	33
付録	35
謝辞	36

# 目次

1.1	Proposed method [1] . . . . .	2
1.2	The proposed method for learning of the person-following behavior[4] . .	3
1.3	Training the neural network [5] . . . . .	5
1.4	The trained network is used to generate steering commands from a single front-facing center camera. [5] . . . . .	5
1.5	How the CNN “sees” an unpaved road. Top: subset of the camera image sent to the CNN. Bottom left: Activation of the first layer feature maps. Bottom right: Activation of the second layer feature maps. This demonstrates that the CNN learned to detect useful road features on its own, i.e., with only the human steering angle as training signal. We never explicitly trained it to detect the outlines of roads. [5] . . . . .	6
2.1	Neural network . . . . .	8
2.2	Structure of end-to-end learning . . . . .	9
2.3	Training the neural network [6] . . . . .	10
2.4	ImageNet classification with deep convolutional neural network [7] . . . .	11
2.5	Hokuyo 2DLiDAR (UTM-30LX) [8] . . . . .	12
2.6	RViz (Display robot model and scan data) . . . . .	13
3.1	Action according to angles of the joint [4] . . . . .	14
3.2	Target trajectory that the operator walks [4] . . . . .	15
3.3	Structure of the network [4] . . . . .	16

4.1	The trained network is used to generate the robot's yaw angular velocity from the RGB images . . . . .	17
4.2	Sequence of proposed method . . . . .	17
4.3	Output robot actions . . . . .	18
4.4	Wearing retroreflective tape . . . . .	18
4.5	Proposed method in the learning phase . . . . .	19
4.6	Without retroreflective tape . . . . .	19
4.7	Proposed method in the following phase . . . . .	20
4.8	Turn left toward the retroreflective tape . . . . .	20
4.9	Turn right toward the retroreflective tape . . . . .	21
4.10	Architecture of the network . . . . .	21
5.1	The environment of the experiment . . . . .	22
5.2	hogehoge . . . . .	23
5.3	The developed system . . . . .	23
5.4	hogehoge . . . . .	24
5.5	Measure the reflection intensity of the wall . . . . .	25
5.6	Measure the reflection intensity of retroreflective tape . . . . .	26
5.7	Measure the reflection intensity of foyer . . . . .	27
5.8	Learning and following phase courses . . . . .	29
5.9	Histogram of angular velocity at success . . . . .	30
5.10	Failed at the first corner . . . . .	30
5.11	Histogram of angular velocity at failure . . . . .	31



# 表目次

3.1	Actions and Control Parameters . . . . .	15
3.2	Parameters of network configured with chainer . . . . .	16

# 第 1 章

## 序論

### 1.1 背景

近年，機械学習を用いた自律移動に関する研究が盛んに行われている．本研究室でも，機械学習を用いた画像に基づく人追従行動の生成に関する研究を行ってきた．

パシンら [1][2][3] は，引き紐を利用して画像に基づく人追従行動を生成する手法を提案している．これは，深層強化学習 [9] を用いており，引き紐に取り付けられたポテンショメータでリンクの角度を取得し，それに応じた報酬をエージェント（ロボット）に与えて強化学習 [10] することで，画像に基づいて人追従する行動を生成できることを示した．Fig. 1.1 にシステムの概要を示す．入力画像で，出力は直進，左旋回，右旋回のいずれかの行動である．報酬は，引き紐を取り付けたリンクの角度に基づいており，人がロボットの正面に立つと報酬が高くなるように設定されている．ロボットは報酬が高くなるよう行動を選択するため，引き紐を持つ人がロボットの正面にいない場合は，引き紐を持つ人がロボットの正面になるように，左旋回や右旋回といった行動を選択する．引き紐を持つ人が正面にいる場合は，ロボットは直進を選択する．さまざまな行動と画像に対して，リンクの角度に応じた報酬を与えることで，徐々に人を追従する適切な行動を選択していった．しかし，強化学習の特性により，行動の選択がランダムに探索される場合がある．その結果，報酬の低い行動が選択され，追従対象者が望まない行動が発生する可能性がある．また，カメラ画像に基づく人追従行動を獲得するまでに約 20 分かかり，その間にロボットは望まない行動を繰り返すため，追従対象者に比較的負担がかかるという問題があった．


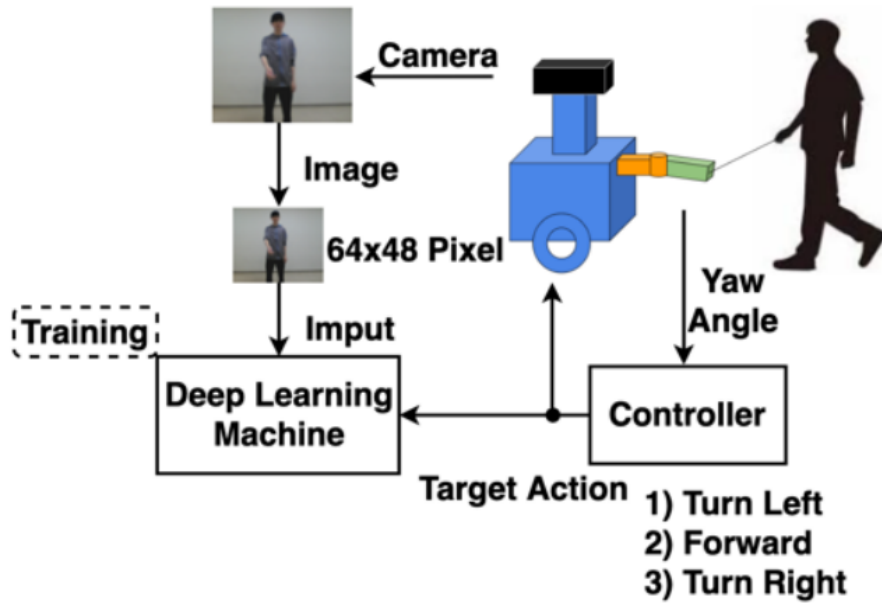



Fig. 1.1: Proposed method [1]

岡田ら [4] は、強化学習のような教師なし学習ではなく、深層学習 [11] という教師あり学習を用いて画像に基づく人追従行動を生成する手法を提案している。これは、後述する Bojarski ら [5] の技術（end-to-end 学習）を人追従問題に応用しており、強化学習を使用していないため、ロボットの行動がランダムに選択されることはない。また、学習時はルールベース制御器でロボットを制御しているので、常に人を追従する。つまり、学習時にも人追従行動を獲得することができ、強化学習を採用する手法と比べて追従対象者の負担が少ないというメリットがある。Fig. 1.2 にシステムの概要を示す。まず、学習時は、追従対象者が引き紐を操作する。引き紐には同じくポテンシオメータが取り付けられていて、ヨー関節の変位角が 0 度となるようにロボットは直進や左旋回、右旋回のいずれかの行動で制御される。並行して、これらの行動とカメラ画像を深層学習器にオンラインで end-to-end 学習する。学習後は、追従対象者が引き紐を操作しなくても、深層学習器によりカメラ画像を入力するだけで、出力は直進や左旋回、右旋回といった行動を選択する。つまり、学習時のルールベース制御器（引き紐による人追従行動）を模倣するような深層学習器（カメラ画像による人追従行動）になっている。

しかし、1) 引き紐のような専用の実験装置が必要。2) 紐を持つ姿勢の画像しか収集できない。といった問題が挙げられる。これらの問題点は、センサの変更で解決できる可能性がある。



(a) Learning phase



(b) Following phase

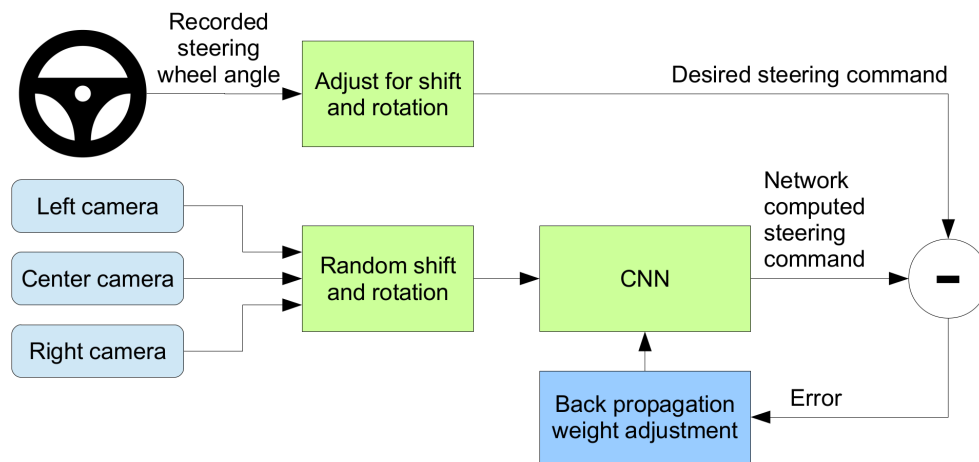
Fig. 1.2: The proposed method for learning of the person-following behavior[4]

## 1.2 目的


本研究では，センサの変更に伴うルールベース制御器による人追従行動を生成する手法を提案し，その出力を教師信号とした画像に基づいて人追従行動が可能かどうか，実ロボットを用いた実験により提案手法の有効性について検証する．

### 1.3 関連研究

Bojarski ら [5] は，カメラ画像と人が操作するステアリングの角度を用いて模倣学習を行うことで，自動車の自動運転に成功している．学習時のシステムを Fig. 1.3 に示す．学習時は，ドライバーが車を運転していて，その時に取得したステアリングの角度とカメラ画像を組み合わせで end-to-end 学習している．これにより，学習後は，Fig. 1.4 に示すようにカメラ画像から直接，ステアリングの角度を出力するシステムになっている．すなわち，カメラ画像のみで自動運転を可能にしている．




**Fig. 1.3:** Training the neural network [5]



**Fig. 1.4:** The trained network is used to generate steering commands from a single front-facing center camera. [5]

Fig. 1.5 は，CNN が白線等のない未塗装道路においても，人が操作するステアリングの角度だけを教師信号として，有用な道路の特徴を学習したことを示している．なお，道路の輪郭を検出するような学習を明示的に行っていない．



**Fig. 1.5:** How the CNN “sees” an unpaved road. Top: subset of the camera image sent to the CNN. Bottom left: Activation of the first layer feature maps. Bottom right: Activation of the second layer feature maps. This demonstrates that the CNN learned to detect useful road features on its own, i.e., with only the human steering angle as training signal. We never explicitly trained it to detect the outlines of roads. [5]

## 1.4 論文の構成

第 1 章では，本研究の背景，目的，関連研究について述べた．第 2 章では，本研究で用いる要素技術について述べる．第 3 章では，本研究の提案手法を述べる．第 4 章では，提案手法を用いた実験を行う．第 5 章では，本研究の結論を述べる．




## 第 2 章

# 要素技術

本章では，本研究で用いた深層学習に関連した要素技術と，引き紐を用いたルールベース制御器，ベースとなる従来手法について述べる．

### 2.1 深層学習


深層学習（Deep learning）は，画像や音声などの複雑なデータを処理するための機械学習手法であり，人工ニューラルネットワークを基盤としている．Fig. 2.1 に示すように，多層のニューロンが組み合わさり，人間の脳のような階層的な構造をしている．これにより，例えば画像や音声の特徴を学習し，自動的に認識や分類を行うことが可能になる．



**Fig. 2.1:** Neural network

## 2.2 end-to-end 学習

end-to-end 学習とは，Fig. 2.2 に示すように，システムの入力から出力までの全体の処理を一つのニューラルネットワークで直接学習する機械学習手法である．この手法では，画像や音声などの特徴抽出や前処理の段階を人手で設計する必要がなく，データから直接目標のタスクを学習することができる．



**Fig. 2.2:** Structure of end-to-end learning

## 2.3 Convolutional Neural Network (CNN)

本研究の学習器は畳み込みニューラルネットワーク（Convolutional Neural Network : CNN）で、これは画像認識などで用いられている [6][7]。ニューラルネットワークに畳み込み層とプーリング層を含み、多次元配列の形式データを処理するように設計されている。例として、LeCun ら [6] は Fig. 2.3 に示すように畳み込み層とプーリング層を連続して接続するネットワークを用いることで、手書き文字を識別できることを示した。また、Krizhevsky ら [7] は深い畳み込みニューラルネットワークを用いることで、1000 種類のクラスに分類できることを示し (Fig. 2.4), ILSVRC(ImageNet Large Scale Visual Recognition Challenge)2012 で優勝した。

CNN は、主に畳み込み層、プーリング層、および全結合層から構成される。以下に、それぞれの特徴を記す。

### 1. 畳み込み層

入力データに対してフィルターを適用し、特徴を抽出した特徴マップを出力する層

### 2. プーリング層

特徴マップのサイズを削減し、特徴の位置に対する頑健性を向上させるために、領域内の最大値や平均値を取る操作を行う層

### 3. 全結合層

畳み込み層とプーリング層で抽出された特徴を組み合わせ、最終的な出力を生成する層




Fig. 2.3: Training the neural network [6]

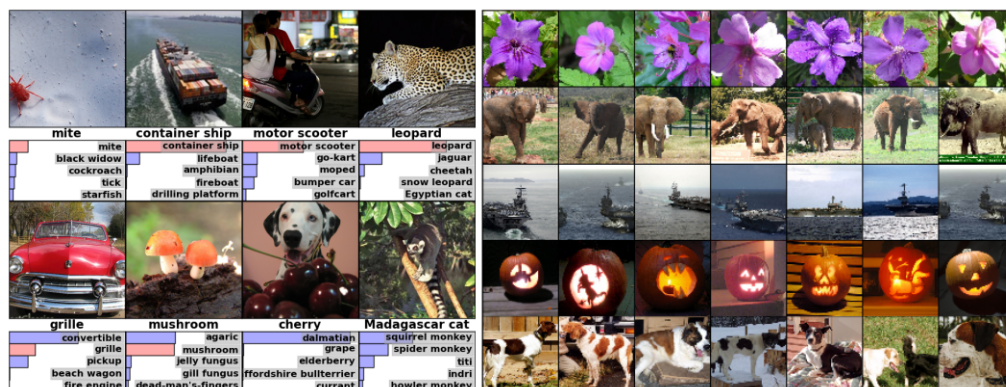


Fig. 2.4: ImageNet classification with deep convolutional neural network [7]

## 2.4 ROS

ROS (Robot Operating System) は、オープンソースのロボットソフトウェアフレームワークで、ロボットアプリケーションの開発や実行をサポートするミドルウェアである。異なるバージョンが存在しているが、本研究では ROS Noetic を対象としている。

### 2.4.1 LiDAR

LiDAR (Light Detection and Ranging) は、光を利用して距離を測定する技術で、具体的には、レーザー光を発射し、対象物に当たって反射し戻ってくるまでの時間を計測することで、距離を推定する。また、使用する装置によっては、物体によってどれだけの光が反射されたかを示す反射強度も測定することができる。したがって、LiDAR は周囲の状況を把握し、環境認識や物体検知などに利用される。


本研究で使用する 2DLiDAR を Fig. 2.5 に示す。これは、北陽社製の 2DLiDAR であり、ROS 上で `urg_node`[12] というパッケージが提供されている。この `urg_node` は、検出範囲（最大 270 度）や反射強度の使用有無などのパラメータを変更するだけで簡単にデータのやり取りが可能である。



**Fig. 2.5:** Hokuyo 2DLiDAR (UTM-30LX) [8]

### 2.4.2 RViz

RViz (ROS Visualization) [13] は, ROS で提供される三次元ビジュアライゼーションツールであり, 数値で表されるロボットの座標や各センサのデータ直感的に理解できる三次元空間上に表示することができる. Fig. 2.6 にその様子を示す. ここでは, ロボットのモデルと 2DLiDAR からのセンサデータ, カメラ画像をリアルタイムに表示している.



**Fig. 2.6:** RViz (Display robot model and scan data)


## 第 3 章

# 従来手法

本研究のベースとなる岡田らの研究（以後、従来手法と呼ぶ）について述べる．従来手法は，引き紐を用いたルールベース制御器による行動を模倣学習し，同様の行動を画像を用いて行う手法である．この手法は，学習フェーズと追従フェーズに分かれている．

### 3.1 学習フェーズ

学習フェーズで使用するルールベース制御器を Fig. 3.1 に示す．ルールベース制御器は，引き紐に取り付けられたポテンシオメータからのリンクの角度を入力とし，ルールに従いロボットの行動を選択する．ルールベース制御器からの出力を Table 3.1 に示す．なお，並進速度は  $0.1 \text{ [m/s]}$  で一定である．



**Fig. 3.1:** Action according to angles of the joint [4]

Table 3.1: Actions and Control Parameters

Action	Control rule	Linear velocity	Angular velocity
Turn Left	$\theta_{yaw} > 10 \text{ deg}$	0.1 m/s	0.2 rad/s
Forward	$-10 \text{ deg} < \theta_{yaw} < 10 \text{ deg}$	0.1 m/s	0 rad/s
Turn Right	$\theta_{yaw} < -10 \text{ deg}$	0.1 m/s	-0.2 rad/s

### 3.2 追従フェーズ

追従フェーズでは，学習フェーズで学習したモデルを活用し，Fig. 3.2 に示す経路（学習フェーズと同じ経路）を使用してテストを行う．この際，引き紐は不要であり，代わりに深層学習器に画像が入力され，その出力がロボットの行動となる．つまり，学習フェーズで利用された引き紐によるルールベース制御器の出力ではなく，カメラ画像に基づく深層学習器の出力がロボットの行動になる．





Fig. 3.2: Target trajectory that the operator walks [4]



### 3.3 ネットワークの構造

ネットワークを Fig. 3.3 に示す．これは，Chainer[14] という深層学習フレームワークで CNN をベースとしており，入力層，畳み込み層 3，全結合層 2，出力層の 7 層で構成されている．また，ハイパーパラメータを Table 3.2 に示す．



**Fig. 3.3:** Structure of the network [4]


**Table 3.2:** Parameters of network configured with chainer

Input data	Image(64x48 pixels, RGB channels)
Optimizer	Adam( $\alpha = 0.001, \beta_1 = 0.9, \beta_2 = 0.999, \epsilon = 1e^{-2}$ )
Loss function	Softmax-cross-entropy
Output data	Action (Forward, Turn Left, Turn Right)


## 第 4 章

# 提案手法


### 4.1 提案手法の概要



**Fig. 4.1:** The trained network is used to generate the robot's yaw angular velocity from the RGB images



**Fig. 4.2:** Sequence of proposed method



**Fig. 4.3:** Output robot actions

## 4.2 学習フェーズ



**Fig. 4.4:** Wearing retroreflective tape




Fig. 4.5: Proposed method in the learning phase

### 4.3 追従フェーズ



Fig. 4.6: Without retroreflective tape




Fig. 4.7: Proposed method in the following phase

#### 4.4 ルールベース制御器


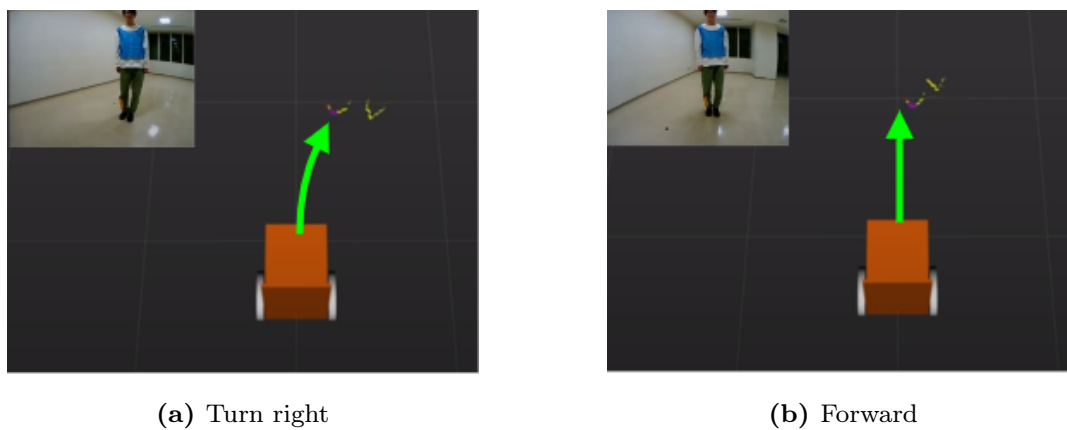



Fig. 4.8: Turn left toward the retroreflective tape



**Fig. 4.9:** Turn right toward the retroreflective tape

## 4.5 ネットワーク構造




**Fig. 4.10:** Architecture of the network

## 第 5 章

# 実験

### 5.1 実験の手順



**Fig. 5.1:** The environment of the experiment




Fig. 5.2: hogehoge

## 5.2 実験装置

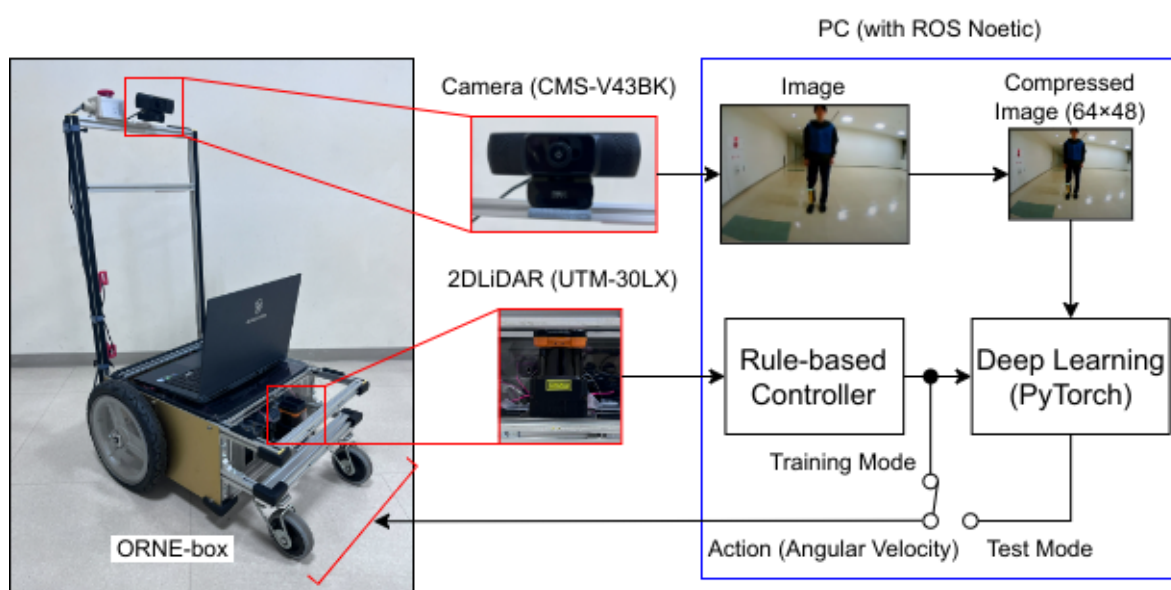



Fig. 5.3: The developed system






**Fig. 5.4:** hogehoge


## 5.3 実験 1 LiDAR の反射強度の実験

### 5.3.1 実験目的

## 5.3.2 壁の反射強度




(a) View from behind




(b) View from the side

**Fig. 5.5:** Measure the reflection intensity of the wall

## 5.3.3 再帰反射テープの反射強度




(a) View from behind



(b) View from the side

**Fig. 5.6:** Measure the reflection intensity of retroreflective tape

## 5.3.4 学習する場所付近の反射強度



**Fig. 5.7:** Measure the reflection intensity of foyer

### 5.3.5 反射強度を利用した人追従の実験

## 5.4 実験2 提案手法による人追従の実験

### 5.4.1 実験目的

### 5.4.2 実験方法




Fig. 5.8: Learning and following phase courses

### 5.4.3 結果と考察




Fig. 5.9: Histogram of angular velocity at success





Fig. 5.10: Failed at the first corner



**Fig. 5.11:** Histogram of angular velocity at failure



## 第 6 章

## 結論

## 参考文献

- [1] ティーラパップパシン, 林原 靖男, “強化学習を用いた移動ロボットの自律化に関する研究 —引き紐の角度を報酬とする人追従の提案—”, 3E3-07, SI2017 (2017).
- [2] ティーラパップパシン, 上田隆一, 林原靖男, “強化学習を用いた移動ロボットの自律化に関する研究 —引き紐を用いて一定間隔で人追従する学習の性能評価—”, 2B3-14, SI2018 (2018).
- [3] ティーラパップパシン, 林原靖男, 上田隆一, “強化学習を用いた移動ロボットの自律化に関する研究 —一定の間隔で人を追従する行動の獲得に関する検討—”, 日本機械学会ロボティクス・メカトロニクス講演会'18 予稿集, 1A1-M11 (2018).
- [4] 岡田真也, 上田隆一, 林原靖男, “引き紐を利用した視覚と行動の End-to-end 学習による移動ロボットの人追従行動の生成”, 2A5-01, SI2019 (2019).
- [5] Mariusz Bojarski et al, “End-to-end Learning for Self-driving Cars”, arxiv: 1604.07316, 2016.
- [6] Yann Lecun et al, “Gradient-based learning applied to document recognition”, Proceedings of the IEEE 86.11 (1998): 2278-2324.
- [7] Krizhevsky, Alex, Ilya Sutskever, and Geoffrey E. Hinton, “Imagenet classification with deep convolutional neural networks”, Advances in neural information processing systems, 2012.
- [8] 北陽電気. UTM-30LX. <https://www.hokuyo-aut.co.jp/search/single.php?serial=21>. (Accessed on 12/27/2023).
- [9] Hado van Hasselt, Arthur Guez, and David Silver, “Deep reinforcement learning with double q-learning”, Thirtieth AAAI conference on artificial intelligence, 2016.
- [10] Leslie Pack Kaelbling, Michael L. Littman, and Andrew W. Moore, “Reinforcement

- learning: A survey”, *Journal of artificial intelligence research* 4, pp.237-285, 1996.
- [11] Yann LeCun, Yoshua Bengio, and Geoffrey Hinton. “Deep learning”, *nature* 521.7553 (2015): 436-444.
- [12] ROS Wiki. `urg_node`. [https://wiki.ros.org/urg\\_node](https://wiki.ros.org/urg_node). (Accessed on 12/27/2023).
- [13] ROS-Visualization. `ros-visualization/rviz` GitHub repository. <https://github.com/ros-visualization/rviz>. (Accessed on 12/27/2023).
- [14] Chainer. チュートリアル. <https://tutorials.chainer.org/ja/>. (Accessed on 12/28/2023).

## 付録

## 謝辞

本研究を進めるにあたり， 1 年に渡り，熱心にご指導を頂いた林原靖男教授に深く感謝いたします。