

修士論文

物体追跡導入による

リアルタイム・ゼロショットセグメンテーション

— 自律走行モビリティにおける認識・判断タスクへの応用 —

Real-time Zero-shot Segmentation through Object Tracking

— Application to Perception and Decision-making Tasks in Autonomous Mobility —

2025 年 10 月 28 日 提出

指導教員 林原 靖男 教授

千葉工業大学 先進工学研究科 未来ロボティクス専攻

24S1036 馬場琉生

概要

物体追跡導入による リアルタイム・ゼロショットセグメンテーション — 自律走行モビリティにおける認識・判断タスクへの応用 —

キーワード:

abstract

Real-time Zero-shot Segmentation through Object Tracking
— Application to Perception and Decision-making Tasks in Autonomous Mobilit —

keywords:

目次

第 1 章	序論	1
1.1	背景	1
1.2	関連研究	5
1.3	研究目的	5
1.4	論文構成	5
第 2 章	要素技術	6
2.1	大規模基盤モデル	6
2.2	ゼロショット物体検出	7
2.3	ゼロショットセグメンテーション	7
第 3 章	提案手法	9
第 4 章	システム構成	11
4.1	物体検出モジュール	12
4.2	物体追跡モジュール	12
4.3	セグメンテーションモジュール	12
第 5 章	提案手法の性能評価	13
5.1	性能評価の方法	13
5.2	結果と考察	13
第 6 章	AI-Formula への応用	16

目次	vi
6.1 実環境での実験方法	17
6.2 実環境での実験結果	20
第 7 章 結論	23
参考文献	24
付録	25
謝辞	26

図目次

1.1	Visualizations of model outputs. (Source: [1])	2
1.2	Example images with overlaid masks from our newly introduced dataset, SA-1B. SA-1B contains 11M diverse, high-resolution, licensed, and privacy protecting images and 1.1B high-quality segmentation masks. These masks were annotated fully automatically by SAM, and as we verify by human ratings and numerous experiments, are of high quality and diversity. We group images by number of masks per image for visualization (there are ~ 100 masks per image on average). (Source: [2])	3
1.3	Language Segment-Anything execution example. (Input Text: “white line. red pylon. road. person. robot. tree. building. traffic light. pedestrian crossing.”)	4
3.1	Overview of the proposed method	10
4.1	Overview of the system	11
5.1	Comparison of Ground Truth, Lang-SAM, and the Proposed Method . .	15
6.1	AI-Formula mobility	17
6.2	Course and obstacle used in the experiment	18
6.3	An example of calculating the vanishing point	19
6.4	Obstacle detection using the BBox area as a threshold	20
6.5	The trajectory of mobility	21

6.6	Result of obstacle detection and stop	22
-----	---	----

表目次

5.1	Experimental environment for evaluation	13
5.2	Experimental results for evaluation	14
6.1	An experimental environment for vanishing point navigation	18

第 1 章

序論

1.1 背景

近年，大規模基盤モデルの発展により，画像認識分野は大きな進歩を遂げている．特に，Transformer アーキテクチャに基づく視覚言語統合モデルの登場により，従来の教師あり学習では困難であった物体認識が可能となった．例えば，テキストプロンプトから物体位置を特定する Grounding DINO [1] や，プロンプトに応じて物体を高精度にセグメンテーションする Segment Anything Model (SAM) [2] が挙げられる．

Grounding DINO は，BERT 由来の言語エンコーダと画像特徴を融合することで，任意の物体カテゴリに対するゼロショット物体検出を実現している．このモデルは，テキストと画像の両方の情報を統合的に処理することで，事前に定義されていない物体カテゴリであっても，自然言語による指示のみで検出が可能となる．Grounding DINO の特徴として，言語情報と視覚情報の深い融合により，文脈を考慮した物体検出が実現されている点が挙げられる．Fig. 1.1 に示されるように，Grounding DINO は多様な物体に対して高精度なバウンディングボックスを生成し，テキストプロンプトに応じた柔軟な物体検出を実現している．この可視化例からは，モデルが複雑なシーン内の複数物体を正確に識別し，位置を特定できることが確認できる．




Fig. 1.1 Visualizations of model outputs. (Source: [1])

一方, SAM は 11 億枚を超える大規模マスクデータセット (SA-1B) で学習され, プロンプト (point, box, mask) に基づく高精度なセグメンテーションを提供する. SA-1B は, 1,100 万枚の多様で高解像度, かつライセンスとプライバシー保護が施された画像と, 11 億の高品質セグメンテーションマスクから構成されている. これらのマスクは SAM によって完全自動でアノテーションされており, 人間による評価と多数の実験により, その高品質性と多様性が検証されている. Fig. 1.2 に示されるように, SAM は 1 画像あたり平均約 100 個のマスクを生成し, 画像内の多様な物体や領域を詳細にセグメンテーションすることができる. この例では, 画像ごとのマスク数によってグループ化された多様なシーンが示されており, SAM の汎用性と精度の高さが確認できる.




Fig. 1.2 Example images with overlaid masks from our newly introduced dataset, SA-1B. SA-1B contains 11M diverse, high-resolution, licensed, and privacy protecting images and 1.1B high-quality segmentation masks. These masks were annotated fully automatically by SAM, and as we verify by human ratings and numerous experiments, are of high quality and diversity. We group images by number of masks per image for visualization (there are ~ 100 masks per image on average). (Source: [2])

この2つのモデルを組み合わせた Language Segment-Anything (Lang-SAM) [3] は、自然言語の指示のみで対象を切り出すゼロショットセグメンテーションを可能にし、事前学習なしに多様な物体クラスへの対応を実現している。Lang-SAM の実行例を Fig. 1.3 に示す。画像と自然言語を入力するだけで、物体検出の結果やセグメンテーションの結果が出力される。



Fig. 1.3 Language Segment-Anything execution example. (Input Text: “white line. red pylon. road. person. robot. tree. building. traffic light. pedestrian crossing.”)

しかし、これらのモデルは高い表現能力と引き換えに膨大な計算コストを要するため、リアルタイムシステムに応用しようとするとき、処理を高頻度で繰り返す必要があり、システム全体の処理速度が遅くなるという問題が生じる。

1.2 関連研究

システム全体の処理速度が遅くなるという問題に対する有効なアプローチとして、高コストな検出と軽量の追跡を組み合わせる Tracking-by-Detection のパラダイムが知られている。このパラダイムは、毎フレーム実行される高精度な物体検出の結果を、軽量の追跡アルゴリズムでフレームをまたいで関連付けることにより、物体の ID を維持し、安定した追跡をリアルタイムで実現するものである。その代表的な手法に SORT (Simple Online and Realtime Tracking) [4] が存在する。SORT は、カルマンフィルタによる物体の運動予測とハンガリアンアルゴリズムにより高速かつ高精度な多物体追跡を実現している。

1.3 研究目的

本研究では、この Tracking-by-Detection の考え方を応用し、言語指示によるゼロショットセグメンテーションのリアルタイム性を向上するために、高コストな物体検出処理の頻度を削減し、その間を軽量の物体追跡で補間する手法を提案する。本手法を時速 6 [km/h] で走行する自律走行モビリティの消失点ナビゲーションおよび障害物検出・停止タスクへ応用し、実環境への適用可能性を調査する。

1.4 論文構成

第 2 章

要素技術

本章では、本研究の基盤となる要素技術について述べる。まず、大規模基盤モデルの概念とその特徴を説明し、次にゼロショット物体検出およびゼロショットセグメンテーションの技術について詳述する。

2.1 大規模基盤モデル

大規模基盤モデル（Foundation Model）とは、大量かつ多様なデータで事前学習された汎用的な機械学習モデルであり、特定のタスクに対して追加学習やプロンプトのみで適応可能な能力を持つ。この技術は、一つのモデルが複数のタスクに対応できる点で、従来のタスク特化型モデルとは根本的に異なる。

大規模基盤モデルの技術的基盤は、Transformer アーキテクチャと自己教師あり学習の組み合わせにある。Transformer は、self-attention 機構により入力データの長距離依存関係を効率的にモデル化する。具体的には、入力シーケンスの各要素が他のすべての要素との関連性を計算し、重要な情報を選択的に抽出する。自己教師あり学習は、人手によるラベル付けを必要とせず、データそのものから学習信号を生成する技術である。例えば、「文中の一部の単語を隠してその単語を予測する」や「画像とテキストの対応関係を学習する」といった方法が用いられる。

重要な技術的概念として、埋め込み空間（Embedding Space）がある。モデルは、入力データを高次元ベクトル空間上の点として表現し、意味的に類似したデータが近くに配置される。

視覚言語統合モデルは、画像とテキストを共通の埋め込み空間にマッピングする技術であり、CLIP はその代表例である。対照学習により、正しいペアの埋め込みベクトル間の距離を近づけ、誤ったペアの距離を遠ざけることで、視覚概念と言語概念の対応関係を学習する。

2.2 ゼロショット物体検出

ゼロショット物体検出とは、学習時に見たことのない物体カテゴリを、テキスト記述のみで検出する技術である。従来の物体検出では、あらかじめ定義された固定カテゴリのみを検出可能であったが、ゼロショット検出は視覚情報と言語情報を統合することで、任意のテキストプロンプトに対応した柔軟な検出を実現する。

この技術の核心は、物体の視覚的特徴と言語的記述を共通の埋め込み空間で対応付けることにある。画像は CNN または Vision Transformer により処理され、多スケールの特徴マップが生成される。テキストプロンプトは BERT などの言語モデルによりエンコードされ、言語特徴ベクトルに変換される。視覚特徴と言語特徴は、cross-attention 機構により相互作用する。言語特徴の各単語が画像特徴の各位置に対して attention 重みを計算し、テキストプロンプト全体に対応する画像領域が特定される。

Grounding DINO は、この技術を実装した代表的なモデルである。入力画像が Swin Transformer により処理され階層的な視覚特徴が抽出され、テキストプロンプトが BERT により言語特徴に変換される。これらの特徴が特徴強化モジュールで相互に強化された後、Transformer デコーダにより物体クエリが生成される。各物体クエリは、bounding box の座標とクラススコアを予測する。

推論時には、ユーザーが任意のテキストプロンプトを入力でき、単一物体の記述から属性を含む記述、関係性を含む記述まで対応可能である。信頼度スコアが閾値（通常 0.3～0.5）を超える検出のみが最終結果として採用される。

2.3 ゼロショットセグメンテーション

セグメンテーションとは、画像内の各ピクセルに対して所属する物体または領域を識別する技術である。ゼロショットセグメンテーションは、学習時に見たことのない物体に対しても、プロンプトに基づいて高精度なマスクを生成する技術である。

Segment Anything Model (SAM) は、プロンプタブルセグメンテーションを実現する基盤モデルであり、点、bounding box、マスクの 3 種類のプロンプトに対応する。そのアーキテクチャは、画像エンコーダ、プロンプトエンコーダ、マスクデコーダの 3 つのコンポーネントから構成される。画像エンコーダは Vision Transformer をベースとし、入力画像を 16×16 ピクセルのパッチに分割して処理する。self-attention 機構により各パッチは画像全体の文脈情報を考慮した表現を獲得し、画像埋め込みが生成される。プロンプトエンコーダは、異なる形式のプロンプトを統一的な表現に変換する。点プロンプトは位置エンコーディングにより、テキストプロンプトは CLIP の言語エンコーダにより高次元ベクトルに変換される。マスクデコーダは、Transformer ベースのアーキテクチャを採用し、双方向の cross-attention により画像埋め込みとプロンプト埋め込みを融合する。出力は画像と同じ解像度を持つバイナリマスクであり、SAM は複数の候補マスク（通常 3 つ）を同時に出力する。これは曖昧なプロンプトに対して複数の妥当な解釈を提示するためである。

Language Segment-Anything (Lang-SAM) は、Grounding DINO と SAM を統合したゼロショットセグメンテーションシステムである。テキストプロンプトが Grounding DINO に入力され対応する物体の bounding box が検出され、この bounding box が SAM のプロンプトとして使用され高精度なセグメンテーションマスクが生成される。

第 3 章

提案手法

本研究では、Fig. 3.1 に示すように、高コストなゼロショットセグメンテーション処理と軽量の物体追跡処理を組み合わせる手法を提案する。これは Tracking-by-Detection の考え方を応用したものであるが、以下の点が異なる。

第一に、SORT などが毎フレームの物体検出を前提とするのに対し、本アプローチではゼロショットモデルから成る認識処理を意図的に間引いて実行する。これは、大規模基盤モデルの高い認識性能を維持しつつ、システム全体のスループットを確保するためである。

第二に、物体検出が行われないフレームでは、追跡処理が出力を補間する役割を担う。これにより、高周波な状態更新が求められるモビリティの制御タスクに対応できる可能性がある。




Fig. 3.1 Overview of the proposed method

第 4 章

システム構成

本章では，提案手法のシステム構成について述べる．Fig. 4.1 に示すように，本手法は，(1) 物体検出，(2) 物体追跡，(3) セグメンテーション，の 3 つのモジュールで構成される．以下にそれぞれのモジュールに関して述べる．




Fig. 4.1 Overview of the system

4.1 物体検出モジュール

テキストプロンプトに基づき、Grounding DINO を用いて物体検出を行う。これによって、テキストに対応するバウンディングボックス（以後、BBox と呼ぶ）が生成される。この処理は、毎フレームではなく一定間隔で実行し、計算負荷が過大とならないようにする。

4.2 物体追跡モジュール

後続のフレームでは、毎フレーム Grounding DINO を実行する代わりに、物体追跡で BBox を更新する。まず、前フレームの BBox 内で Shi-Tomasi 法 [5] に基づき画像特徴点を抽出する。次に、抽出した特徴点群を Lucas-Kanade 法 [6] に基づくピラミッドオプティカルフローで追跡し、その移動ベクトルの中央値を算出する。このベクトルを用いて BBox の位置と大きさを更新する。以上の一連の処理を繰り返し実行する。これらの手法は、標準的かつ計算効率に優れていることから、特徴点追跡に採用した。

4.3 セグメンテーションモジュール

検出または追跡によって更新された BBox に対し、SAM2 を用いてセグメンテーションマスクを生成する。これは、比較的小さいモデルを使用して毎フレーム実行する。これにより、検出から追跡、セグメンテーションまでの一連の処理を行う。

第 5 章

提案手法の性能評価

5.1 性能評価の方法

本章では，提案手法の基本的な性能を明らかにするための評価実験について述べる．この実験の目的は，従来手法と比較して提案手法がどの程度処理速度を向上させるか，またその際にどの程度の検出位置の正確度を維持できるかを定量的に評価することである．実験環境の詳細を Table 5.1 に示す．コンピュータは後述のモビリティの制御に用いる NVIDIA Jetson AGX Orin (32GB) を使用し，MOT17 データセット [7] を使用した．また，テキストプロンプトには “pedestrian” を指定した．

Table 5.1 Experimental environment for evaluation

Computer	NVIDIA Jetson AGX Orin 32GB
Input Text	”pedestrian.”
Grounding DINO	grounding-dino-base
SAM Model	sam2.1_hiera_small

5.2 結果と考察

評価指標には，システム全体の処理速度を示す FPS (Frames Per Second) と，BBox の正確度を示す IoU (Intersection over Union) の 2 つを用いた．評価データには，mot17-02-frcnn の 600 フレームを用いた．比較対象として，毎フレーム物体検出を行う従来手法 (Lang-SAM)

でも同様の評価を行った。

実験結果を Table 5.2 に示す。提案手法は従来手法に比べて処理速度を向上させる一方で、正確度の低下も確認された。この結果は、本手法において処理速度と正確度がトレードオフの関係にあることを示している。検出結果の一例を Fig. 5.1 に示す。図中では、正解データを赤色で、従来手法を青色で、提案手法を緑色で示している。図のように、完全一致ではないものの、提案手法により歩行者を概ね正しく検出できていることがわかる。

Table 5.2 Experimental results for evaluation

Method	FPS	IoU
Conventional	0.79	0.814
Proposed (Redetection interval: 2.0s)	2.15	0.707



Fig. 5.1 Comparison of Ground Truth, Lang-SAM, and the Proposed Method

第 6 章

AI-Formula への応用

実環境への適用可能性を調査するため、自律走行競技会 AI-Formula [8] における消失点ナビゲーションおよび障害物検出・停止タスクへ提案手法の応用を試みた。Fig. 6.1 に AI-Formula のモビリティを示す。モビリティには、ステレオカメラ、GNSS、IMU が搭載されている。本競技会では、実環境におけるリアルタイム認識と制御が要求される実践的な評価環境が提供されている。




Fig. 6.1 AI-Formula mobility

6.1 実環境での実験方法

実環境への適用可能性を調査するため、モビリティがスタートラインから時速 6 [km/h] で経路を走行し、コースアウトせずに障害物の手前で停止できるかの挙動を確認する。実験環境の詳細は Table 6.1 の通りである。テキストプロンプトには, “white line. road. red pylon.” を指定して, その内の “white line” を消失点ナビゲーション, “red pylon” を障害物検出・停止タスクに用いた。走行経路は Fig. 6.2 に示す通り, 破線の無い白線部分を対象とし, スタートから 20 [m] 先に障害物を設置した。

Table 6.1 An experimental environment for vanishing point navigation

Computer	NVIDIA Jetson AGX Orin 32GB
Middleware	ROS 2 Humble
Input Image	480x300
Input Text	"white line. road. red pylon."
Grounding DINO	grounding-dino-base
SAM Model	sam2.1_hiera_small




Fig. 6.2 Course and obstacle used in the experiment

提案手法によるセグメンテーションの結果を用いて、消失点ナビゲーションへ応用する実験を行う。ナビゲーションでは、最初に提案手法を用いてセグメンテーションされた白線を抽出する。次に、ハフ変換により 2 本の白線を求め、その消失点を算出する。最後に、算出した消

消失点が画像中心に位置するように，PID 制御に基づきモビリティのヨー角速度を制御することで白線の消失点に向かって進むようにする．これによって，モビリティはレーンの白線に沿って経路を走行する．本手順による処理結果を Fig. 6.3 に示す．図中では，ハフ変換の出力を青線で，消失点を赤点で示している．




Fig. 6.3 An example of calculating the vanishing point

提案手法による物体検出および物体追跡の結果を用いて，障害物検出・停止タスクへ応用する実験を行う．実験では，Fig. 6.4 の赤いパイロンを障害物とする．モビリティがパイロンに接近し，検出した BBox の面積が事前に設定したしきい値を超えた場合に自動停止させる．しきい値は，実験開始前にモビリティの 5m 手前にパイロンを置き，そのときに検出される BBox の面積を計測して設定した．



Fig. 6.4 Obstacle detection using the BBox area as a threshold

6.2 実環境での実験結果

本実験では、時速 6 [km/h] で走行する自律走行モビリティを用いて、消失点ナビゲーションおよび障害物検出・停止タスクを実環境で行い、その適用可能性を調査した。その結果、モビリティは指定コースを逸脱することなく走行し、障害物手前で停止した。つまり、一例ではあるが、提案手法により事前学習なく環境を認識してコースを走行・停止できることを確認した。以下に、各タスクにおけるモビリティの挙動を詳述する。

Fig. 6.5 に、GNSS データに基づき作成したモビリティの走行軌跡を示す。指定した約 20m のコースを逸脱することなく、一定速度で走行することを確認した。ただし、部分的に蛇行する挙動も見られた。これは、システムの処理負荷増大による制御周波数の低下が原因と考えられる。認識処理のみでは 2.15 FPS であった処理速度が、消失点ナビゲーションなどを含むシ

ステム全体では低下したため，この処理遅延が蛇行につながったおそれがある．

Fig. 6.6 に，障害物検出・停止タスクの結果を示す．事前に設定した目標停止距離 5 [m] に対し，モビリティは障害物の約 3.4 [m] 手前で停止し，目標と 1.6 [m] の誤差が生じた．これは，モビリティの制動距離に加え，システム全体の処理遅延も影響していると考えられる．




Fig. 6.5 The trajectory of mobility




Fig. 6.6 Result of obstacle detection and stop

第 7 章

結論

本研究では、自然言語の指示のみで画像から対象を切り出すゼロショットセグメンテーションに物体追跡を追加し、リアルタイム性を向上する手法を提案した。提案手法の評価では、処理速度を 2.7 倍に向上できた一方で、IoU が 0.107 低下するトレードオフも見られた。

また、実環境への適用可能性を調査するため、提案手法を AI-Formula に応用した。その結果、モビリティは指定したコースを逸脱せず、障害物の手前で停止した。今後は、さらなる高速化に取り組み、AI-Formula のレースや他のロボット技術チャレンジへの応用を目指す。

参考文献

- [1] S. Liu, Z. Zeng, T. Ren, F. Li, H. Zhang, J. Yang, C. Li, J. Gao, C. Li, and L. Yuan. Grounding dino: Marrying dino with grounded pre-training for open-set object detection. *arXiv preprint arXiv:2303.05499*, 2023.
- [2] Alexander Kirillov, Eric Mintun, Nikhila Ravi, Hanzi Mao, Chloe Rolland, Laura Gustafson, Tete Xiao, Spencer Whitehead, Alexander C. Berg, Wan-Yen Lo, Piotr Dollár, and Ross Girshick. Segment anything. *arXiv:2304.02643*, 2023.
- [3] L. Medeiros. Lang-segment-anything, 2023. GitHub repository.
- [4] A. Bewley, Z. Ge, L. Ott, F. Ramos, and B. Upcroft. Simple online and realtime tracking. In *2016 IEEE International Conference on Image Processing (ICIP)*, pp. 3464–3468, 2016.
- [5] J. Shi and C. Tomasi. Good features to track. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 593–600, 1994.
- [6] B. D. Lucas and T. Kanade. An iterative image registration technique with an application to stereo vision. In *Proceedings of the 7th international joint conference on Artificial intelligence*, Vol. 2, pp. 674–679, 1981.
- [7] A. Milan, L. Leal-Taixé, I. Reid, S. Roth, and K. Schindler. Mot16: A benchmark for multi-object tracking. *arXiv preprint arXiv:1603.00831*, 2016.
- [8] M. Okada, I. Omura, Y. Akimoto, K. Sakazaki, S. Ebita, A. Kato, and Y. Yasui. Operations and platform design for the ai-formula. In *Proceedings of the 2025 SICE Festival with Annual Conference*, pp. 1112–1115, Chiang Mai, Thailand, 2025. Honda R&D Co., Ltd.

付録

謝辞

本研究を進めるにあたり，1年に渡り，熱心にご指導を頂いた林原靖男教授に深く感謝いたします。

なぜこのコミットを見に来た？呪うぞ！

明日は球技大会（ソフトボール）です。

巷では，チェンソーマンのレゼ編が上映されています。